

线性代数(2023-2024)第十三次作业

1 复习知识点

- 牢记Gram–Schmidt算法，熟练掌握如何用Gram–Schmidt算法将一个内积空间里的一组基底转化为一组标准正交基底。作为重要应用，熟练掌握使用Gram–Schmidt算法得到对称矩阵的各个特征空间的标准正交基底，从而将对称矩阵正交对角化。
- 二次型的定义，orthogonal change of variables的定义，Theorem 7.17 (The principal axes theorem)的内容，以及熟练掌握如何用orthogonal change of variables化简一个给定的二次型，参考讲义196页-197页，198页-199页的两个例子。
- 二次型的positive definite, negative definite, indefinite与其对应的对称矩阵特征值的关系，如何判断一个对称矩阵是否是positive definite。
- 熟练掌握QR分解与奇异值分解(SVD)的具体计算过程。

2 习题部分

Problem A(6 Points)

令 V 为一个内积空间， $\langle \cdot, \cdot \rangle$ 为 V 上的内积。假设 $S = \{\mathbf{u}_1, \dots, \mathbf{u}_n\}$ 是 V 的一组基底。对 S 使用Gram–Schmidt算法，依次得到

$$\begin{aligned} \mathbf{v}_1 &= \mathbf{u}_1 / \|\mathbf{u}_1\|; \\ \mathbf{v}_2 &= \frac{\mathbf{u}_2 - \langle \mathbf{u}_2, \mathbf{v}_1 \rangle \mathbf{v}_1}{\|\mathbf{u}_2 - \langle \mathbf{u}_2, \mathbf{v}_1 \rangle \mathbf{v}_1\|}; \\ \mathbf{v}_j &= \frac{\mathbf{u}_j - \langle \mathbf{u}_j, \mathbf{v}_1 \rangle \mathbf{v}_1 - \dots - \langle \mathbf{u}_j, \mathbf{v}_{j-1} \rangle \mathbf{v}_{j-1}}{\|\mathbf{u}_j - \langle \mathbf{u}_j, \mathbf{v}_1 \rangle \mathbf{v}_1 - \dots - \langle \mathbf{u}_j, \mathbf{v}_{j-1} \rangle \mathbf{v}_{j-1}\|}, j = 1, \dots, n. \end{aligned}$$

用尽量严格的数学语言证明，对任何 $j = 1, \dots, n$ ，都有

$$\text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_j\} = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_j\}.$$

Problem B(6 Points), 2022-2023年线性代数期末考试题

Let $\mathbf{u}_1, \dots, \mathbf{u}_m$ be m vectors in \mathbb{R}^n . Denote by “ \cdot ” the Euclidean inner product on \mathbb{R}^n . Prove that $\mathbf{u}_1, \dots, \mathbf{u}_m$ are linearly dependent if and only if the determinant

$$\begin{vmatrix} \mathbf{u}_1 \cdot \mathbf{u}_1 & \mathbf{u}_1 \cdot \mathbf{u}_2 & \dots & \mathbf{u}_1 \cdot \mathbf{u}_m \\ \mathbf{u}_2 \cdot \mathbf{u}_1 & \mathbf{u}_2 \cdot \mathbf{u}_2 & \dots & \mathbf{u}_2 \cdot \mathbf{u}_m \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{u}_m \cdot \mathbf{u}_1 & \mathbf{u}_m \cdot \mathbf{u}_2 & \dots & \mathbf{u}_m \cdot \mathbf{u}_m \end{vmatrix} = 0.$$

Problem C(6 Points)

已知 $\mathbf{v} = (1, 1, 1)$ 是二次型 $Q_A(\mathbf{x}) = 2x_1^2 + x_2^2 + ax_3^2 + 2x_1x_2 + 2bx_1x_3 + 2x_2x_3$ 对应的对称矩阵 A 的一个特征向量, 其中 a, b 为待定实数。

1. (2 points) 求 a 与 b 的值, 并求出对阵矩阵 A 。
2. (3 points) 利用 orthogonal change of variables $\mathbf{y} = P^\top \mathbf{x}$ 求出二次型关于 $\mathbf{y} = (y_1, y_2, y_3)$ 的表达式。
3. (1 point) 判断对称矩阵 A 是否是 positive definite。

Problem D(6 Points), 2022-2023年线性代数期末延期考试题

Let $A = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 0 & 1 \\ -1 & -1 & 1 \end{bmatrix}$. Find a decomposition $A = QRP$ such that: P and Q are orthogonal matrices, and

$$R = \begin{bmatrix} a & 0 & d \\ 0 & b & e \\ 0 & 0 & c \end{bmatrix}$$

is an upper triangular matrix with $a, b, c, d, e \in \mathbb{R}$.

Problem E(6 Points), 最小二乘法

通过这道题目, 我们简单了解一个线性代数的具体应用: 最小二乘法(Least Squares)与最佳逼近(Best Approximation)。

这个应用的背景如下: 假设 $A \in M_{m \times n}$ 与 $\mathbf{b} \in \mathbb{R}^m$ 给定, 但方程组 $A\mathbf{x} = \mathbf{b}$ 无解。我们试图找到一个向量 $\mathbf{x} \in \mathbb{R}^n$ 使得 $A\mathbf{x}$ 与 \mathbf{b} 的距离尽可能的小, 即:

$$\|\mathbf{b} - A\mathbf{y}\| \geq \|\mathbf{b} - A\mathbf{x}\| > 0$$

对任何 $\mathbf{y} \in \mathbb{R}^n$ 都成立。满足这个条件的向量 $\mathbf{x} \in \mathbb{R}^n$ 被称为最小二乘法(Least Squares)的解, $\mathbf{b} - A\mathbf{x}$ 被称为最小二乘法误差向量(least squares error vector), $\|\mathbf{b} - A\mathbf{x}\|$ 被称为最小二乘法误差(least squares error)。

现在我们讨论如何求出这个最小二乘法的解 \mathbf{x} 。这里我们需要用到下面的这个结论。

- (1 point) 令 V 为一个内积空间, $\langle \cdot, \cdot \rangle$ 为 V 上的一个内积, W 是 V 的一个有限维子空间, $\mathbf{b} \in V$ 。证明对于任何 $\mathbf{w} \in W$, 都有

$$\|\mathbf{b} - \text{proj}_W(\mathbf{b})\| \leq \|\mathbf{b} - \mathbf{w}\|,$$

且等号只有当 $\mathbf{w} = \text{proj}_W(\mathbf{b})$ 时才能取到。

提示: 对于任何 $\mathbf{w} \in W$, 我们有

$$\mathbf{b} - \mathbf{w} = (\mathbf{b} - \text{proj}_W(\mathbf{b})) + (\text{proj}_W(\mathbf{b}) - \mathbf{w}).$$

由于 \mathbf{b} 可以表示为 $\mathbf{b} = \text{proj}_W(\mathbf{b}) + \text{proj}_{W^\perp}(\mathbf{b})$ (讲义Theorem 7.15), 我们又有 $\mathbf{b} - \text{proj}_W(\mathbf{b}) = \text{proj}_{W^\perp}(\mathbf{b})$, 因此 $\mathbf{b} - \text{proj}_W(\mathbf{b})$ 实际上与 $\text{proj}_W(\mathbf{b}) - \mathbf{w} \in W$ 正交。因此利用勾股定理可得

$$\|\mathbf{b} - \mathbf{w}\|^2 = \|\mathbf{b} - \text{proj}_W(\mathbf{b})\|^2 + \|\text{proj}_W(\mathbf{b}) - \mathbf{w}\|^2.$$

利用这一等式可完成证明。

现在令 $V = \mathbb{R}^m$ 为欧式内积空间。那么以上结果告诉我们

- (1 point) 证明: $\mathbf{x} \in \mathbb{R}^n$ 是最小二乘法的解当且仅当 $A\mathbf{x} = \text{proj}_W(\mathbf{b})$, 这里 W 是 A 的列空间。

现在, 为了求解 $A\mathbf{x} = \text{proj}_W(\mathbf{b})$ (W 是 A 的列空间), 我们首先将其写为

$$\mathbf{b} - A\mathbf{x} = \mathbf{b} - \text{proj}_W(\mathbf{b}).$$

等式两边同乘以 A^\top , 可得

$$A^\top(\mathbf{b} - A\mathbf{x}) = A^\top(\mathbf{b} - \text{proj}_W(\mathbf{b})) = A^\top(\text{proj}_{W^\perp}(\mathbf{b})).$$

- (1 point) 证明: $A^\top(\text{proj}_{W^\perp}(\mathbf{b})) = \mathbf{0}$ 。

因此, 由以上结果, 我们实际上得到, $\mathbf{x} \in \mathbb{R}^n$ 是最小二乘法的解当且仅当 $A^\top(\mathbf{b} - A\mathbf{x}) = A^\top(\text{proj}_{W^\perp}(\mathbf{b})) = \mathbf{0}$, 也即当且仅当 $\mathbf{x} \in \mathbb{R}^n$ 满足方程

$$(A^\top A)\mathbf{x} = A^\top \mathbf{b}.$$

以上方程也被称为normal system。

- (3 points) 令 $A = \begin{bmatrix} 1 & -1 \\ 3 & 2 \\ -2 & 4 \end{bmatrix}$, $\mathbf{b} = \begin{bmatrix} 4 \\ 1 \\ 3 \end{bmatrix}$ 。证明 $A\mathbf{x} = \mathbf{b}$ 无解, 并利用normal system $(A^\top A)\mathbf{x} = A^\top \mathbf{b}$ 求出最小二乘法的解 \mathbf{x} , 接着求出最小二乘法的误差 $\|\mathbf{b} - A\mathbf{x}\|$ 。

Bonus: 不计入分数, 但强烈建议亲手计算

- 计算 $A = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}$ 的QR分解。

- 计算 $A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}$ 的奇异值分解(SVD)。

Deadline: 22:00, January 14.

作业提交截止时间：1月14日晚上22:00。